

Adult Census Income · 의 사결정나무 분류 분석 보고서

ML Auto Flow

June 26, 2026

CONTENTS

Adult Census Income · 의사결정나무(Decision Tree) 분류 분석 보고서	
1. 요약 (Executive Summary)	
2. 데이터셋 개요	
3. 변수(컬럼) 사전	
4. 타깃 분포와 클래스 불균형	
5. 분석 진행 과정 (파이프라인)	
5.1 [1] LoadData — 데이터 적재	
5.2 [2] SplitData — 학습/평가 분할	
5.3 [3] DecisionTree — 모델 정의	
5.4 [4] TrainModel — 학습	
5.5 [5] ScoreModel — 예측(채점)	
5.6 [6] EvaluateModel — 평가	
6. 분석 결과와 해석	
6.1 기본 성능 지표 (임계값 0.50)	
6.2 혼동행렬 (Confusion Matrix, 임계값 0.50)	
6.3 임계값(Threshold) 조정의 효과 ★	
6.4 ROC 곡선과 AUC	
6.5 정밀도-재현율(PR) 곡선	
7. 재현성 (Reproducibility)	

8. 결론 및 한계

Adult Census Income · 의사결정나무(Decision Tree) 분류 분석 보고서

부제: Book-Ch3 예제 — 데이터셋 구조·내용과 분석 진행 과정 상세 설명 · 2026-06-26

목적: 본 문서는 ML Auto Flow에 내장된 큐레이션 예제 `Book_AdultIncome_DecisionTree` (미국 인구조사 소득 분류)의 ① 데이터셋 구조·내용과 ② 분석이 진행되는 전 과정을 단계별로 상세히 설명하여, 이 모델이 무엇을 어떻게 학습·평가하는지 파악할 수 있도록 작성되었습니다.

본문의 모든 수치는 앱에서 동일 파이프라인을 실제 실행하여 얻은 결과이며, 내보낸 standalone Python 코드로 결정적으로(재현 가능) 동일하게 재현됩니다.

1. 요약 (Executive Summary)

- **과제 유형:** 이진 분류(Binary Classification) — 한 개인의 연 소득이 **\$50,000 초과(>50K)**인지 이하(**<=50K**)인지 예측.
- **데이터:** UCI Machine Learning Repository의 **Adult(Census Income)** 데이터셋. **32,561행 × 15열**(특성 14 + 타겟 1).
- **클래스 불균형:** **<=50K** 24,720건(75.9%) vs **>50K** 7,841건(24.1%) — **약 3:1 불균형**. 이 점이 평가 지표 해석의 핵심.
- **모델:** 의사결정나무(Decision Tree), `criterion=gini`, `max_depth=8`. 입력은 수치형 6개 특성 (age, fnlwgt, education-num, capital-gain, capital-loss, hours-per-week).
- **분석 흐름:** `LoadData` → `SplitData(80/20)` → `DecisionTree(정의)` → `TrainModel` → `ScoreModel` → `EvaluateModel`.
- **핵심 결과**(테스트셋 $n \approx 6,513$, 임계값 0.50): 정확도 **0.8320**, 정밀도 **0.8126**, 재현율 **0.3947**, F1 **0.5313**, ROC-AUC **0.8548**.
- **시사점:** 정확도는 높아 보이지만 이는 다수 클래스(**<=50K**) 비중이 커서 나타나는 착시가 있으며, 소수 클래스(**>50K**) **재현율이 0.39로 낮음**. 임계값(threshold)을 낮추면 재현율을 크게 끌어올릴 수 있어(0.20에서 재현율 0.81), 목적에 맞는 임계값 선택이 중요하다.

강조: “정확도 83%”라는 단일 숫자만 보면 좋아 보이지만, 불균형 데이터에서는 **AUC·정밀도·재현율·임계값별 곡선**을 함께 봐야 모델을 올바르게 이해할 수 있다. 본 보고서 5~6장이 이 부분을 다룬다.

2. 데이터셋 개요

항목	내용
데이터셋 이름	Adult (Census Income)
출처	UCI Machine Learning Repository (미국 인구조사국 1994년 자료 기반)
파일	<code>adult.csv</code> (앱 내 <code>Examples_in_Load/</code> , <code>verify/datasets/</code>)
행 수	32,561 (헤더 제외)
열 수	15 (입력 특성 14 + 타겟 1)
과제	이진 분류 — 연 소득 <code>>50K</code> 여부 예측
타겟 변수	<code>income</code> (<code><=50K</code> / <code>>50K</code>)

원본 데이터 표본(처음 5행):

age	work-class	education	education-num	marital-status	occupation	hours-per-week	income
39	State-gov	Bachelors	13	Never-married	Adm-clerical	40	<=50K
50	Self-emp-not-inc	Bachelors	13	Married-civ-spouse	Exec-managerial	13	<=50K
38	Private	HS-grad	9	Divorced	Handlers-cleaners	40	<=50K
53	Private	11th	7	Married-civ-spouse	Handlers-cleaners	40	<=50K
28	Private	Bachelors	13	Married-civ-spouse	Prof-specialty	40	<=50K

출처: `verify/datasets/adult.csv` (헤더 + 1~5행)

3. 변수(컬럼) 사전

데이터셋의 15개 컬럼을 유형·의미·예시와 함께 정리한다. 연속(수치형) 6개, 범주(문자형) 8개, 타깃 1개로 구성된다.

#	컬럼명	유형	의미	예시 값
1	age	연속	나이(세)	39, 50, 28
2	workclass	범주	고용 형태	Private, Self-emp-not-inc, State-gov
3	fnlwgt	연속	<i>final weight</i> — 인구조사 표본 가중치 (해당 표본이 대표하는 인구 수)	77516, 215646
4	education	범주	최종 학력(명목)	Bachelors, HS-grad, 11th
5	education-num	연속	학력 연수(= education 의 순서형 수치 인코딩)	13, 9, 7
6	marital-status	범주	혼인 상태	Married-civ-spouse, Never-married, Divorced
7	occupation	범주	직업군	Exec-managerial, Prof-specialty, Adm-clerical
8	relationship	범주	가구 내 관계	Husband, Wife, Not-in-family
9	race	범주	인종	White, Black
10	sex	범주	성별	Male, Female
11	capital-gain	연속	자본 이득(달러)	2174, 0
12	capital-loss	연속	자본 손실(달러)	0
13	hours-per-week	연속	주당 근로시간	40, 13
14	native-country	범주	출신 국가	United-States, Cuba
15	income	타깃 (범주)	연 소득 구간	<=50K , >50K

분석상 중요 포인트: 이 예제 모델은 위 14개 특성 중 **수치형 6개만**(age, fnlwgt, education-num, capital-gain, capital-loss, hours-per-week) 사용한다. `occupation`, `education`, `marital-status` 같은 **범주형 정보는 이 예제에서 사용하지 않는다**(범주형을 쓰려면 별도 인코딩 모듈이 필요). 따라서 본 모델은 “수치 정보만으로 소득을 추정”하는 단순화된 기준선(baseline)이며, 이는 4장·6장에서 다시 언급한다.

4. 타겟 분포와 클래스 불균형

타겟 `income`의 분포는 다음과 같다.


클래스	의미	건수	비율
<code><=50K</code>	연 소득 5만 달러 이하	24,720	75.9%
<code>>50K</code>	연 소득 5만 달러 초과	7,841	24.1%
합계		32,561	100%

출처: `adult.csv` `income` 컬럼 집계

- 다수 클래스(`<=50K`)가 약 **76%**를 차지하는 **불균형 데이터**다.
- 이 때문에 “무조건 `<=50K`로 찍는” 무의미한 모델조차 **약 76% 정확도**를 얻는다. 즉 **정확도만으로는 모델의 실력을 판단할 수 없다**.
- 분석에서 소수 클래스(`>50K`)를 얼마나 잘 잡아내는지(**재현율**)와, 임계값 전반의 분리 성능(**AUC**)이 더 중요한 지표가 된다.

5. 분석 진행 과정 (파이프라인)

본 예제는 6개 모듈이 순서대로 연결된 파이프라인이다. 각 모듈의 역할·파라미터·입출력을 단계별로 설명한다.



5.1 [1] LOADDATA — 데이터 적재

- **역할:** `adult.csv` (32,561행)를 표 형태(DataFrame)로 읽어 들인다.
- **파라미터:** `source = "adult.csv"`.
- **출력:** 15개 컬럼 전체를 담은 데이터.

5.2 [2] SPLITDATA — 학습/평가 분할

- **역할:** 데이터를 **학습용(train)**과 **평가용(test)**으로 나눈다. 모델은 학습 데이터로만 배우고, 한 번도 보지 않은 평가 데이터로 성능을 측정해야 **과적합 없는 일반화 성능**을 알 수 있다.
- **파라미터:** `train_size=0.8` (80% 학습 / 20% 평가), `random_state=42` (난수 고정 → **재현성**), `shuffle=True`, `stratify=False`.
- **결과 규모:** 학습 약 **26,048행**, 평가 약 **6,513행**.

`random_state=42`로 분할 난수를 고정하기 때문에 **몇 번을 실행해도 같은 분할·같은 결과가 나온**다. 이는 본 앱의 재현성 원칙의 핵심이다.

5.3 [3] DECISIONTREE — 모델 정의

- **역할:** 학습에 사용할 **의사결정나무 분류기**의 구조(하이퍼파라미터)를 정의한다(이 단계는 아직 학습하지 않고 “설정”만 만든다).
- **파라미터:**
 - `model_purpose = classification` — 분류용.
 - `criterion = gini` — 분기 품질 척도로 **지니 불순도(Gini impurity)** 사용. 한 노드가 한 클래스로 순수할수록 불순도가 낮다.
 - `max_depth = 8` — 나무의 최대 깊이를 8로 제한(과적합 방지·해석 가능성 확보).
 - `min_samples_split = 2`, `min_samples_leaf = 1` — 분기/말단 노드의 최소 표본 수(기본값).

의사결정나무란? 데이터를 “예/아니오” 질문(예: `capital-gain > 5000?`)으로 반복 분할하여, 각 말단(leaf)에서 다수 클래스로 예측하는 모델이다. 규칙이 사람이 읽을 수 있어 **해석 가능성이 높고**, 수치 특성의 비선형 관계도 잡아낸다. 깊이를 제한(`max_depth=8`)하면 일반화가 좋아진다.

5.4 [4] TRAINMODEL — 학습

- **역할:** 학습 데이터로 의사결정나무를 **실제로 적합(fit)**시킨다.
- **파라미터:**
 - `feature_columns = [age, fnlwgt, education-num, capital-gain, capital-loss, hours-per-week]` — 입력 특성 6개(수치형).
 - `label_column = income` — 예측 대상.

- **출력:** 학습된 모델(분기 규칙 + 각 특성의 중요도).

5.5 [5] SCOREMODEL — 예측(채점)

- **역할:** 학습된 모델로 데이터의 각 행에 대해 예측을 생성한다.
- **출력 컬럼:**
 - `Predict` — 예측된 클래스(하드 라벨, `<=50K` 또는 `>50K`).
 - `income_Predict_Proba_0`, `income_Predict_Proba_1` — 각 클래스의 **예측 확률**. 양성 클래스 (`>50K`) 확률(`..._Proba_1`)이 임계값 조정·ROC 곡선의 근거가 된다.

5.6 [6] EVALUATEMODEL — 평가

- **역할:** 실제값(`income`)과 예측(`Predict` / 확률)을 비교해 분류 성능을 계산한다.
- **파라미터:** `model_type=classification`, `label_column=income`, `prediction_column=Predict`, `threshold=0.5`.
- **산출물:** 정확도/정밀도/재현율/F1, 혼동행렬, **임계값 스윙 표**, **ROC 곡선·AUC**, **정밀도-재현율(PR) 곡선·평균정밀도** — 6장에서 상세히 해석한다.

6. 분석 결과와 해석

아래 수치는 평가용 테스트셋($n \approx 6,513$, 학습에 쓰이지 않은 데이터)에서 측정한 값이다.

6.1 기본 성능 지표 (임계값 0.50)

지표	값	의미
Accuracy(정확도)	0.8320	전체 중 맞춘 비율
Precision(정밀도)	0.8126	<code>>50K</code> 로 예측한 것 중 실제 <code>>50K</code> 비율
Recall(재현율)	0.3947	실제 <code>>50K</code> 중 모델이 잡아낸 비율
F1-Score	0.5313	정밀도·재현율의 조화평균
ROC-AUC	0.8548	임계값 전반의 분리 성능(1에 가까울수록 우수)
Average Precision(PR-AUC)	0.5364	불균형 데이터에서 유용한 PR 곡선 아래 면적

6.2 혼동행렬 (CONFUSION MATRIX, 임계값 0.50)

	예측: ≤50K	예측: >50K
실제: ≤50K	TN = 4,799	FP = 143
실제: >50K	FN = 951	TP = 620

- 실제 >50K (고소득) **1,571명 중 620명만** 잡아냄(FN 951명 놓침) → **재현율 0.39**.
- >50K 로 예측한 763명 중 620명이 실제 고소득 → **정밀도 0.81**(예측이 보수적이라 틀리게 고소득이라 외치는 경우는 적음).
- 즉 이 모델은 **확실할 때만 “고소득”이라 판정**하는 경향(보수적). 고소득자를 폭넓게 찾아내야 하는 목적에는 임계값 하향이 필요.

6.3 임계값(THRESHOLD) 조정의 효과 ★

EvaluateModel은 0.00~1.00 구간의 임계값을 바(슬라이더)로 조절하며 지표가 어떻게 변하는지 보여 준다(양성 클래스 확률 income_Predict_Proba_1 기준). 임계값을 **낮추면** 더 적극적으로 >50K 라 판정 → 재현율↑·정밀도↓, **높이면** 반대.

임계값	Accuracy	Precision	Recall	해석
0.20	0.7305	0.4663	0.8103	고소득자를 폭넓게 포착(재현율↑) 대신 오탐↑
0.50	0.8320	0.8126	0.3947	기본값(정확도 최대 부근)
0.80	0.8277	0.9517	0.3011	매우 확실한 경우만 판정(정밀도↑)

핵심 해석: “올바른 임계값”은 하나로 정해져 있지 않다. **고소득자를 놓치면 안 되는 목적**(예: 타깃 마케팅 후보 확보)이라면 임계값을 0.2 부근으로 낮춰 **재현율 0.81**을 택하고, **잘못된 고소득 판정 비용이 큰 목적**이라면 임계값을 높여 정밀도를 우선한다. 이 트레이드오프를 한눈에 보여주는 것이 임계값 스위치 표와 다음의 곡선들이다.

6.4 ROC 곡선과 AUC

- **ROC 곡선:** 임계값을 0→1로 움직일 때 (거짓양성률 FPR, 참양성률 TPR=재현율) 좌표를 그린 곡선. 좌상단(낮은 FPR·높은 TPR)에 가까울수록 우수.
- **AUC = 0.8548** — 무작위 분류기(AUC 0.5)보다 크게 우수하며, 임의의 고소득자가 임의의 비고소득자보다 높은 점수를 받을 확률이 약 **85%(=0.85)**임을 의미한다. 정확도(0.83)보다 AUC가 모델의 **본질적 분리력**을 더 잘 대변한다.

6.5 정밀도-재현율(PR) 곡선

- **Average Precision(PR-AUC) = 0.5364**. PR 곡선은 불균형 데이터에서 ROC보다 보수적·현실적인 평가를 제공한다(양성 비율 24% 대비 유의미하게 높음).

7. 재현성 (Reproducibility)

본 예제의 모든 분석은 검증 가능한 Python으로 재현된다.

- 캔버스 모듈은 브라우저 내 Python(Pyodide)으로 실행되고, “전체 코드 보기”는 외부에서 그대로 실행되는 **standalone Python**을 내보낸다.
- 모든 난수는 고정(`random_state=42`)되어 **2회 실행 결과가 byte 단위로 동일**하며, 회귀 검증(`npm run verify:pipelines`, 픽스처 `13_book_adult_clf`)이 이를 강제한다.
- EvaluateModel이 내보내는 Python에는 **임계값 스윙 표(0.00~1.00, 21행)·ROC 곡선(21점)·AUC**가 포함되어, 앱에서 본 결과를 사용자의 환경에서 그대로 산출할 수 있다.
- 내보낸 코드 실측 검증: 사다리꼴 적분 **AUC = 0.854369**가 sklearn `roc_auc_score`와 일치, 2회 실행 동일.

8. 결론 및 한계

결론

- 의사결정나무(깊이 8)는 수치형 6개 특성만으로 **AUC 0.85**의 양호한 분리력을 보인다.
- 기본 임계값(0.5)에서는 정확도(0.83)·정밀도(0.81)는 높지만 **재현율(0.39)이 낮아** 고소득자를 절반 이상 놓친다.
- **임계값을 목적에 맞게 조정**하면(예: 0.2) 재현율을 0.81까지 끌어올릴 수 있어, 분류 의사결정은 단일 임계값이 아니라 **곡선 전체와 목적**을 보고 정해야 한다.

한계 및 개선 방향

- 본 예제는 **범주형 특성(직업·학력·혼인상태 등)을 사용하지 않는다**. 이들을 인코딩(예: 원-핫/순서형)해 추가하면 성능 향상 여지가 크다.
- `fnlwgt` (인구조사 가중치)는 개인 소득과 인과적 관련이 약한 표본 가중치로, 특성에서 제외하는 것을 검토할 수 있다.
- 불균형(76:24) 보정을 위해 `class_weight` 조정, 임계값 최적화, 또는 앙상블(RandomForest/Gradient Boosting) 적용을 고려할 수 있다.

본 보고서는 ML Auto Flow `Book_AdultIncome_DecisionTree` 예제의 실제 실행 결과를 기반으로 작성되었습니다. 데이터 출처: UCI Adult (Census Income). 수치는 테스트셋($n \approx 6,513$, `random_state=42`) 기준입니다.